بسمه تعالى

مستندات پروژه پایانی کارشناسی با موضوع طراحی و پیاده سازی موتور جستجوگر وب

استاد راهنما: دکتر مهدی یعقوبی

دانشجو: مسلم آخوندی

دانشکده فنی مهندسی گرگان – دانشگاه گلستان

رشته مهندسی کامپیوتر – گرایش مهندسی نرم افزار (سیستمهای اطلاعاتی)

فهرست مطالب:

Y	آشنایی با موتورهای جستجوگر
μ	توضیحات پروژه
c	بخش خزنده وب (WebCrawler)
۲	بخش ایندکسر (Indexer)
" Λ	بخش رتبه بندی (Ranker)
2L	بخش جستجو (Search)
ΔV	پایگاه داده (Database)

آشنایی با موتورهای جستجوگر وب

موتور جستُجوی وب به انگلیسی Web search engine ابزاریست که به منظور جُستجو در وب برای بدستآوردن اطلاعات درخواست شده، به کار میرود. نتایج یافته شده بهطور معمول در صفحهای با عنوان صفحهٔ نتایج جستجو (Search engine results page)فهرست میشوند.

با استفاده از کلمهٔ کلیدی (keyword)که در واقع توضیحی است کوتاه دربارهٔ آنچه لازم است در اینترنت پیدا شود، کلمه کلیدی باید تا آنجا که ممکن است کوتاه، جزیی و دقیق باشد. به غیر از وارد کردن کلمهٔ مستقیم، میتوان با استفاده از عملگرهایی عمل جستجو را دقیق تر و منظم تر انجام داد.

چگونگی عملکرد موتورهای جستجوی وب

موتورهای جستجوی وب برای آنکه بتوانند به درخواستها و جستجوهای کاربران پاسخ مناسبی بدهند باید دو کار مهم را انجام دهند:

• خزیدن در وبسایتها و ایندکس کردن صفحات

موتورهای جستجو با استفاده از خزندههای خود میتوانند تمامی صفحات و فایلهای موجود در وب را ایندکس کنند. این خزندهها با ورود به هر صفحه به دنبال لینکها هستند تا با دنبال کردن آنها وارد صفحات جدید شوند. با این روش، موتورهای جستجو میتوانند تمامی صفحات موجود در وب را ایندکس کنند.

• رتبهبندی وبسایتها و نمایش بهترین نتایج

اصلی ترین وظیفهٔ موتورهای جستجوی وب، ارائهٔ بهترین و مرتبط ترین نتایج به کاربران است. موتورهای جستجو برای آنکه بتوانند بهترین نتایج را هنگام جستجوی یک عبارت خاص به کاربران نمایش دهند، قوانین و استانداردهایی برای وبسایتها تعریف کردهاند تا بتوانند علاوه بر دسترسی ساده تر به صفحات وبسایتها، محتوای موجود در صفحات را بهتر درک کنند. با این کار، موتورهای جستجو می توانند وبسایتهایی که دارای بیشترین ارتباط معنایی با عبارت جستجو شده توسط کاربر هستند در رتبههای بالاتری در نتایج جستجو قرار دهند.

موتورهای جستجو برای ایجاد نتیجه یک جستجو، تعدادی فعالیت انجام میدهند:

خزش یا Crawling فرایند واکشی تمام صفحات وب لینک شده به یک وب سایت؛ که با استفاده از نرمافزارهایی به نام خزشگر(Crawler) انجام میشود. خزشگر گوگل Google bot نام دارد.

اندیس گذاری یا Indexing فرایند ایجاد اندیس برای تمام صفحات واکشی شده و ذخیره و نگهداری این اندیسها در یک پایگاه داده بسیار بزرگ که در آینده استفاده شوند. به عبارتی، فرایند اندیس گذاری از یک طرف شناسایی کلمات و عباراتی است که صفحه را به خوبی توصیف میکند و از طرف دیگر انتساب کلمات کلیدی یافت شده به صفحه میباشد.

پردازش یا Processing وقتی درخواست جستجو به موتور جستجو میرسد، موتور جستجو آن را پردازش میکند. در واقع موتور جستجو رشته جستجو را با صفحات اندیس شده در پایگاه داده مقایسه میکند.

محاسبه ارتباط یا Relevancy از آنجایی که ممکن است بیشتر از یک صفحه حاوی رشته جستجو باشند، بنابراین موتور جستجو جستجو شروع به محاسبه ارتباط هر صفحه با رشته جستجو میکند. برگرداندن نتیجه: آخرین گامی که موتور جستجو انجام میدهد، بازیابی بهترین نتیجه منطبق میباشد. به عبارت ساده، این فعالیت چیزی نیست جز نمایش اطلاعات در مرورگر.

از نرم افزارهای موتور جستجوگر وب می توان به ..., Google, Bing, Yahoo Search, baidu, Yandex اشاره کرد.

توضيحات پروژه

موضوع پروژه: طراحی و پیاده سازی موتور جستجوگر وب

لینک گیت هاب: https://github.com/ariantron/WebSearchEngine

بخش ها:

نرم افزار پایگاه داده	زبان برنامه نویسی	عنوان	ردیف
MySQL	Java	خزنده وب (WebCrawler)	1
MySQL	Java	ایندکسر (Indexer)	۲
MySQL	Java	رتبه بندی (Ranking)	٣
MySQL	PHP (Laravel framework)	جستجو (Search)	k

کتابخانههای مورد استفاده:

لینک	موضوع	عنوان	ردیف
https://mvnrepository.com/artifact/	پردازش صفحات html	Jsoup	١
org.jsoup/jsoup			
https://mvnrepository.com/artifact/	پردازش صفحات html	htmlcleaner	۲
mysql/mysql-connector-java			
https://mvnrepository.com/artifact/	ارتباط با دیتابیس MySQL در جاوا	mysql-connector-java	٣
net.sourceforge.htmlcleaner/htmlcl			
eaner			

بخش خزنده وب (WebCrawler)

در این بخش، نتیجتاً مجموعه ای از لینکها ساخته میشود که محتوای html هر یک از آنها در بخش ایندکسر تجزیه و تحلیل می گردد و اطلاعاتی که در بخش رتبهبندی مورد کاربرد است توسط ایندکسر، در پایگاه داده فهرست میشود.

در این بخش از دو کلاس Spider و SpiderLeg جهت انجام عملیات Crawling استفاده شده است. پارامتر ورودی متد سازنده کلاس SpiderLeg ، یک متغیر از نوع String است که نشان دهنده لینکی است که عملیات SpiderLeg سازنده کلاس SpiderLeg ، یک متغیر از نوع String است که نشان دهنده لینکی است که عملیات html مربوط به لینک آن میخواهد انجام شود. متد سازنده پس از بررسی ارتباط نرمافزار با شبکه اینترنت محتوای صفحه html مربوط به لینک را پردازش میکند و لینکهای موجود در آن را که عمدتاً در تگ های a میباشند را مییابد. لینکهای یافتشده در صورتی که قبلاً به پایگاه داده افزوده نشده باشند، یک رکورد مرتبط با آنها در جدول sull در پایگاه داده ثبت میگردد. همچنین ارتباط بین لینکها در جدول sinks در جدول اینکها برای و getValidateUrls و extractUrlsFromSite به ترتیب عملیات استخراج لینکها از یک این و دریافت url های معتبر از یک صفحه html را در کلاس SpiderLeg انجام می دهند.

در کلاس Spider، از کلاس SpiderLeg در متدهای start آبجکت تعریف میگردد. ورودی متدهای سازنده این آبجکتها توسط کلاس Spider فراهم میشود به این ترتیب که در کلاس Spider با به کار بردن متد nextUrl هر بار ورودی جدیدی با یافتن لینکهای جدید فراهم میشود و به متد سازنده آبجکتهای کلاس SpiderLeg پاس داده میشود. در متد start در کلاس Spider یین قابلیت وجود دارد که یک وبسایت تا تعداد مشخصی از لینکها عملیات Spider انجام شود.

وب سایت هایی که جهت Crawling انتخاب میشود میتواند لیستی از پیش تهیه شده باشد و یا با یک dns server در ارتباط باشد و دریافت اطلاعات داشته باشد. در این پروژه به صورت آزمایشی وب سایتهای دانشگاهی ایالات متحده آمریکا به عنوان منبع Crawling در نظر گرفته شده است.

در کلاس DataAccess ، توسط متد ، getConnection یک آبجکت از کلاس Connection ایجاد می شود. این کلاس مسئولیت برقراری ارتباط نرم افزار جاوا با دیتابیس MySQL را بر عهده دارد. کوئری های موردنیاز جهت انجام متدهای مربوط به Crawling ابتدا در متغیرهای PreparedStatement ذخیره و سپس با متد excute اجرا میشوند.

کلاس utill شامل متدهای متفرقه ای است که در طول برنامه نویسی این بخش مورد کاربرد بوده است که شامل متدهای getUrlHtml ،getPageTitleFromUrl ،getPageTitleFromHtml می باشد که به ترتیب عملیات استخراج عنوان از محتوای html ، استخراج عنوان از url و استخراج محتوای html از url را بر عهده دارند.

در ادامه کدهای هر یک کلاس مذکور، آورده شده است.

: Spider کلاس

```
package Crawler;
import java.sql.ResultSet;
import java.sql.SQLException;
import java.util.ArrayList;
import java.util.List;
public class Spider {
    private List<String> hasVisited = new ArrayList<>();
    private List<String> toVisit = new ArrayList<>();
    public static Spider getInstance() {
        return new Spider();
    public static void start() throws SQLException, ClassNotFoundException {
        DataAccess dataAccess=DataAccess.getAccess();
        dataAccess.resetCrawlingTables();
        ResultSet resultSet = dataAccess.getWebsites();
        String url;
        while (true) {
            resultSet.first();
                url = resultSet.getString("url");
                getInstance().start(url, 10);
            } while (resultSet.next());
        }
    }
    public void start(String url, int size) throws SQLException,
ClassNotFoundException {
        toVisit.add(url);
        while (hasVisited.size() < size) {</pre>
            String next = nextUrl();
            if (next != null) {
                SpiderLeg leg = new SpiderLeg(next);
                if (toVisit.size() < 10000) toVisit.addAll(leg.getLinks());</pre>
            } else break;
        }
     System.out.println("[Done] Visited " + hasVisited.size() + " web page(s).");
        utill.writeALine();
    }
    public void start(String url) throws SQLException, ClassNotFoundException {
        toVisit.add(url);
        while (true) {
            String next = nextUrl();
            if (next != null) {
                SpiderLeg leg = new SpiderLeg(next);
                if (toVisit.size() < 10000) toVisit.addAll(leg.getLinks());</pre>
            } else break;
      System.out.println("[Done] Visited " + hasVisited.size() + " web page(s).");
        utill.writeALine();
```

```
private String nextUrl() {
    String nextUrl;
    do {
        if (toVisit.size() > 0) nextUrl = toVisit.remove(0);
        else return null;
    } while (hasVisited.contains(nextUrl));
    hasVisited.add(nextUrl);
    return nextUrl;
}
```

: SpiderLeg

```
package Crawler;
import org.jsoup.Connection;
import org.jsoup.Jsoup;
import org.jsoup.nodes.Document;
import org.jsoup.nodes.Element;
import org.jsoup.select.Elements;
import java.io.IOException;
import java.sql.SQLException;
import java.util.ArrayList;
import java.util.List;
public class SpiderLeg {
    private static final String USER_AGENT = "Mozilla/5.0 (Windows NT 6.1; WOW64)"
            " AppleWebKit/535.1 (KHTML, like Gecko) Chrome/13.0.782.112
Safari/535.1";
    private static int count;
    private List<String> links = new ArrayList<>();
    private DataAccess dataAccess;
    public SpiderLeg(String url) throws SQLException, ClassNotFoundException {
        dataAccess = DataAccess.getAccess();
        count++;
        System.out.println("[Number] " + count);
        boolean success;
        try {
            Connection connection = Jsoup.connect(url).userAgent(USER_AGENT);
            Document htmlDocument = connection.get();
            if (connection.response().statusCode() == 200) { // 200 is the HTTP OK
status code
                if (connection.response().contentType().contains("text/html")) {
                    String title = utill.getPageTitleFromUrl(url);
                    if (!isUrlAlreadyAdded(url)) dataAccess.addNode(url, title);
                    dataAccess.setIndexTrue(url);
                    System.out.println("[Visit] " + url);
                    ArrayList<String> linksOnPage =
extractUrlsFromSite(htmlDocument.baseUri());
                    System.out.println(" - Found (" + linksOnPage.size() + ")
links");
                    System.out.println("title: " + title);
                    utill.writeALine();
                    long sourceId = getID(url);
                    for (String link : linksOnPage) {
                        links.add(link);
                        if (!isUrlAlreadyAdded(link)) dataAccess.addNode(link,
utill.getPageTitleFromUrl(link));
                        long targetId = getID(link);
                        if (sourceId != targetId) dataAccess.createLink(sourceId,
targetId);
                    success = true;
                } else {
                    System.out.println("[FailureA] " + url);
                    utill.writeALine();
```

```
success = false;
            }
        }
    } catch (Exception e) {
        System.out.println("[FailureB] " + url);
        utill.writeALine();
        success = false;
    }
}
private ArrayList<String> extractUrlsFromSite(String url) throws IOException {
    Document doc = Jsoup.connect(url).userAgent(USER_AGENT).get();
    Elements links = doc.getElementsByTag("a");
    return getValidateUrls(doc, links);
}
private ArrayList<String> getValidateUrls(Document doc, Elements links) {
    ArrayList<String> urls = new ArrayList<>();
    for (Element link : links) {
        String linkUrl = link.attr("href");
        if (linkUrl.length() > 0) {
            if (linkUrl.length() < 4) {</pre>
                linkUrl = doc.baseUri() + linkUrl.substring(1);
            } else if (!linkUrl.substring(0, 4).equals("http")) {
                linkUrl = doc.baseUri() + linkUrl.substring(1);
        if (linkUrl.isEmpty()) {
            continue;
        urls.add(linkUrl);
    }
    return urls;
}
private boolean isUrlAlreadyAdded(String url) throws SQLException {
    return dataAccess.isNodeAlreadyExisting(url);
private long getID(String url) throws SQLException {
    return dataAccess.getID(url);
public List<String> getLinks() {
    return links;
```

}

: DataAccess

```
package Crawler;
import java.sql.*;
import java.util.ArrayList;
public class DataAccess {
    private static DataAccess access;
    private PreparedStatement addNewNodeStatement;
    private PreparedStatement findIdForUrlStatement;
    private PreparedStatement setIndexTrueStatement;
    private PreparedStatement createLinkStatement;
    private PreparedStatement[] resetCrawlingTablesStatements;
    private PreparedStatement getWebsites;
    private DataAccess() throws SQLException {
        init();
    public static Connection getConnection() {
        Connection connection = null;
        try {
            Class.forName("com.mysql.jdbc.Driver");
            connection = DriverManager.getConnection(
                    "jdbc:mysql://localhost:3306/search_engine", "root", "");
        } catch (Exception e) {
            e.printStackTrace();
        return connection;
    }
    public static DataAccess getAccess() throws SQLException,
ClassNotFoundException {
        if (access == null) {
            access = new DataAccess();
        return access;
    }
    private void init() throws SQLException {
        Connection dbConnection = getConnection();
        findIdForUrlStatement = dbConnection.prepareStatement("SELECT id FROM urls
WHERE url=?;");
        addNewNodeStatement = dbConnection.prepareStatement("INSERT INTO urls
(url,title) VALUES(?,?);");
        createLinkStatement = dbConnection.prepareStatement("INSERT INTO links
(source, target) VALUES(?,?);");
        resetCrawlingTablesStatements = new PreparedStatement[]{
                dbConnection.prepareStatement("DELETE FROM urls;"),
                dbConnection.prepareStatement("DELETE FROM links;"),
                dbConnection.prepareStatement("ALTER TABLE urls AUTO_INCREMENT =
1;"),
                dbConnection.prepareStatement("ALTER TABLE links AUTO_INCREMENT =
1;"),
        setIndexTrueStatement = dbConnection.prepareStatement("UPDATE urls SET
is_index=TRUE WHERE url=?");
```

```
getWebsites = dbConnection.prepareStatement("SELECT url FROM websites");
    }
    public boolean addNode(String url,String title) throws SQLException {
        addNewNodeStatement.setString(1, url);
        addNewNodeStatement.setString(2, title);
        return addNewNodeStatement.execute();
    }
    public boolean isNodeAlreadyExisting(String url) throws SQLException {
        findIdForUrlStatement.setString(1, url);
        return findIdForUrlStatement.executeQuery().next();
    }
    public long getID(String url) throws SQLException {
        findIdForUrlStatement.setString(1, url);
        ResultSet resultSet = findIdForUrlStatement.executeQuery();
        resultSet.first();
        return resultSet.getLong("id");
    }
    public boolean setIndexTrue(String url) throws SQLException {
        setIndexTrueStatement.setString(1, url);
        return setIndexTrueStatement.executeUpdate() > 0;
    }
    public boolean createLink(long sourceID, long targetID) throws SQLException {
        createLinkStatement.setLong(1, sourceID);
        createLinkStatement.setLong(2, targetID);
        return createLinkStatement.execute();
    }
    public void resetCrawlingTables() throws SQLException {
        executeMultiStatement(resetCrawlingTablesStatements);
    }
    private void executeMultiStatement(PreparedStatement[] preparedStatements)
throws SQLException {
        for (PreparedStatement preparedStatement : preparedStatements) {
            preparedStatement.executeUpdate();
        }
    }
    public ResultSet getWebsites() throws SQLException {
        return getWebsites.executeQuery();
    }
}
```

كلاس lutill :

```
package Crawler;
import java.io.BufferedReader;
import java.io.IOException;
import java.io.InputStreamReader;
import java.net.URL;
import java.net.URLConnection;
import java.util.regex.Matcher;
import java.util.regex.Pattern;
public class utill {
    public static void writeALine() {
        System.out.println("-----
    }
    public static String getPageTitleFromHtml(String html) {
        Pattern p = Pattern.compile("<head>.*?<title>(.*?)</title>.*?</head>",
Pattern.DOTALL);
        Matcher m = p.matcher(html);
        String title = "";
        while (m.find()) {
            title = m.group(1);
        return title;
    }
    public static String getPageTitleFromUrl(String url) throws IOException {
        return getPageTitleFromHtml(getUrlHtml(url));
    }
    public static String getUrlHtml(String url) throws IOException {
        StringBuilder stringBuilder = new StringBuilder();
        try {
            URL theUrl = new URL(url);
            URLConnection conn = theUrl.openConnection();
            BufferedReader br = new BufferedReader(
                    new InputStreamReader(conn.getInputStream()));
            String inputLine;
            while ((inputLine = br.readLine()) != null) {
                stringBuilder.append(inputLine);
            br.close();
        } catch (Exception ignored) {
        return stringBuilder.toString();
    }
}
```

بخش ایندکسر:

در این بخش از پروژه، اطلاعات موردنیاز جهت رتبه بندی لینک های یافت شده در بخش Crawler، جمعآوری و فهرست میشود. کلاس اصلی مورد کاربرد در این بخش، کلاس Indexer میباشد. این کلاس شامل متدهایی است که مجموعه کلمات محتوانی متنی فایل های html را استخراج می کند. کلمات بی اهمیت (stop words) مانند کلمات ربطی را حذف میکنند و در دیتابیس با ذکر تعدادشان در هر url آن را ذخیره می کنند.

متد getKeywordsFromUrl : با دریافت آدرس url مجموعه ی کلمات کلیدی محتوای متنی فایل html مربوط به url به دست میآید.

متد insertWords : فرایند ذخیره کلمه در دیتابیس را انجام میدهد. پس از اینکه کنترل شد که کلمه قبلاً در دیتابیس اضافه نشده است. آن کلمه به عنوان یک رکورد در جدول words ثبت میگردد. همچنین پس از هر بار تکرار کلمه در url به فیلد freq آن کلمه در جدول word_doc یک واحد نیز اضافه میگردد.

متد websitesIndex : مجموعه url های معتبر (در زمان دسترسی به محتوا، کاربر با خطایی مثل ۴۰۴ مواجه نشود.) را از دیتابیس دریافت و با بهره گیری از متدهای فوق عملیات indexing را در مورد هر یک از url ها انجام میدهد.

متد start: با فراخوانی این متد در یک حلقه ی بینهایت (از این رو که محتوای url ها دائماً در حال تغییر هستند.) عملیات indexing لینک های دیتابیس انجام میشود.

کلاس EnglishStopWords: مجموعه لغات کم اهمیت زبان انگلیسی را در یک آرایه استاتیک ذخیره کرده است. و امکان دسترسی به این آرایه از طریق این کلاس داریم.

کلاس Stemmer: این کلاس ریشه کلمات را با به کارگیری قواعدی در دستور زبان می یابد.

کلاس Tokenizer: این کلاس با استفاده از کلاس Stemmer علاوه بر ریشه یابی کلمات، کلمات stop words و خالی را حذف می کند و برای عملیات indexing آماده میکند.

کلاس utill: شامل سه متد متفرقه textToWordsList ،writeALine و getUrlHtml است که به ترتیب رسم یک خط ساده، تبدیل متن به لیست کلمات و استخراج محتوای html از یک url را انجام میدهند.

کلاس DataAccess : در این کلاس توسط متد getConnection، یک آبجکت از کلاس Connection ایجاد می شود. این کلاس مسئولیت برقراری ارتباط نرم افزار جاوا با دیتابیس MySQL را بر عهده دارد. کوئری های موردنیاز جهت انجام متدهای مربوط به Indexing ابتدا در متغیرهای PreparedStatement ذخیره و سیس با متد excute اجرا میشوند.

: Indexer

```
package Indexer;
import org.jsoup.Jsoup;
import org.jsoup.safety.Whitelist;
import java.io.IOException;
import java.sql.ResultSet;
import java.sql.SQLException;
import java.util.ArrayList;
public class Indexer {
    private DataAccess dataAccess;
    private Indexer() throws SQLException {
        this.dataAccess = DataAccess.getAccess();
    public static Indexer getInstance() throws SQLException {
        return new Indexer();
    private static String[] getKeywordsFromUrl(String url) {
        String html = utill.getUrlHtml(url);
        String text = Jsoup.clean(html, Whitelist.simpleText());
        ArrayList<String> arrayList = utill.textToWordsList(text);
        Tokenizer tokenizer = new Tokenizer(arrayList,
EnglishStopWords.stopWords);
        return tokenizer.getProcessedWords().split(" ");
    }
    public static void start() throws SQLException {
        DataAccess.getAccess().resetIndexingTables();
        while (true)
            getInstance().websitesIndex();
    }
    private void insertWords(String url) throws SQLException {
        String[] words = getKeywordsFromUrl(url);
        long docUrlId = dataAccess.getID(url);
        int docSize = words.length;
        if (!dataAccess.isAlreadyInsertedInDocSize(docUrlId))
            dataAccess.insertDocSize(docUrlId, docSize);
        boolean isAlreadyAdded;
        long wordId;
        for (String item : words) {
            isAlreadyAdded = dataAccess.isWordAlreadyExisting(item);
            if (isAlreadyAdded) {
                wordId = dataAccess.getWordId(item);
                if (dataAccess.isAlreadyWordAddedToUrl(wordId, docUrlId)) {
                    dataAccess.increaseWordFreq(docUrlId, wordId);
                    System.out.println("update word--doc:" + docUrlId + ",word:" +
item);
                } else {
                    dataAccess.addWord2(wordId, docUrlId, 1);
                    System.out.println("new word--doc:" + docUrlId + ",word:" +
item);
                }
```

```
} else {
                dataAccess.addWord(item);
                wordId = dataAccess.getWordId(item);
                dataAccess.addWord2(wordId, docUrlId, 1);
                System.out.println("new word--doc:" + docUrlId + ",word:" + item);
            }
        }
    }
    private void websitesIndex() throws SQLException {
        ResultSet resultSet = dataAccess.getRightUrls();
        String url;
        int id;
        resultSet.first();
        do {
            url = resultSet.getString("url");
            id = resultSet.getInt("id");
            insertWords(url);
            System.out.println("url -> id:" + id + "\n" + url);
            utill.writeALine();
        } while (resultSet.next());
    }
}
```

کلاس Stemmer:

```
package Indexer;/*
   Porter stemmer in Java. The original paper is in
       Porter, 1980, An algorithm for suffix stripping, Program, Vol. 14,
       no. 3, pp 130-137,
   See also http://www.tartarus.org/~martin/PorterStemmer
   History:
   Release 1
   Bug 1 (reported by Gonzalo Parra 16/10/99) fixed as marked below.
   The words 'aed', 'eed', 'oed' leave k at 'a' for step 3, and b[k-1]
   is then out outside the bounds of b.
   Release 2
   Similarly,
   Bug 2 (reported by Steve Dyrdahl 22/2/00) fixed as marked below.
   'ion' by itself leaves j = -1 in the test for 'ion' in step 5, and
   b[j] is then outside the bounds of b.
   Release 3
   Considerably revised 4/9/00 in the light of many helpful suggestions
   from Brian Goetz of Quiotix Corporation (brian@quiotix.com).
   Release 4
//import java.io.*;
/**
 * Stemmer, implementing the Porter Stemming Algorithm
 * The Stemmer class transforms a word into its root form. The input
 * word can be provided a character at time (by calling add()), or at once
 * by calling one of the various stem(something) methods.
class Stemmer {
    private static final int INC = 50;
    private char[] b;
                       /* offset into b */
    private int i,
            i_end, /* offset to end of stemmed word */
            j, k;
    /* unit of size whereby b is increased */
    public Stemmer() {
        b = new char[INC];
        i = 0;
        i_end = 0;
    }
```

```
* Add a character to the word being stemmed. When you are finished
 * adding characters, you can call stem(void) to stem the word.
public void add(char ch) {
    if (i == b.length) {
        char[] new_b = new char[i + INC];
        for (int c = 0; c < i; c++) new_b[c] = b[c];</pre>
        b = new_b;
    b[i++] = ch;
}
 * Adds wLen characters to the word being stemmed contained in a portion
 * of a char[] array. This is like repeated calls of add(char ch), but
 * faster.
public void add(char[] w, int wLen) {
    if (i + wLen >= b.length) {
        char[] new_b = new char[i + wLen + INC];
        for (int c = 0; c < i; c++) new_b[c] = b[c];</pre>
        b = new b;
    for (int c = 0; c < wLen; c++) b[i++] = w[c];
}
* After a word has been stemmed, it can be retrieved by toString(),
* or a reference to the internal buffer can be retrieved by getResultBuffer
 * and getResultLength (which is generally more efficient.)
public String toString() {
    return new String(b, 0, i_end);
}
/**
 * Returns the length of the word resulting from the stemming process.
public int getResultLength() {
    return i_end;
}
* Returns a reference to a character buffer containing the results of
 * the stemming process. You also need to consult getResultLength()
 * to determine the length of the result.
public char[] getResultBuffer() {
    return b;
/* cons(i) is true <=> b[i] is a consonant. */
private final boolean cons(int i) {
```

```
switch (b[i]) {
         case 'a':
         case 'e':
         case 'i':
         case 'o':
         case 'u':
             return false;
         case 'y':
             return (i == 0) ? true : !cons(i - 1);
         default:
             return true;
     }
 }
/* m() measures the number of consonant sequences between 0 and j. if c is
   a consonant sequence and v a vowel sequence, and <..> indicates arbitrary
  presence,
      <c><v>
                   gives 0
                   gives 1
      <c>vc<v>
      <c>vcvc<v> gives 2
      <c>vcvcvc<v> gives 3
*/
 private final int m() {
     int n = 0;
     int i = 0;
     while (true) {
         if (i > j) return n;
         if (!cons(i)) break;
         i++;
     }
     i++;
     while (true) {
         while (true) {
             if (i > j) return n;
             if (cons(i)) break;
             i++;
         }
         i++;
         n++;
         while (true) {
             if (i > j) return n;
             if (!cons(i)) break;
             i++;
         i++;
     }
 }
 /* vowelinstem() is true <=> 0,...j contains a vowel */
 private final boolean vowelinstem() {
     for (i = 0; i \leftarrow j; i++) if (!cons(i)) return true;
     return false;
 }
```

```
/* doublec(j) is true \langle = \rangle j,(j-1) contain a double consonant. */
 private final boolean doublec(int j) {
     if (j < 1) return false;</pre>
     if (b[j] != b[j - 1]) return false;
     return cons(j);
/* cvc(i) is true <=> i-2,i-1,i has the form consonant - vowel - consonant
   and also if the second c is not w,x or y. this is used when trying to
   restore an e at the end of a short word. e.g.
      cav(e), lov(e), hop(e), crim(e), but
      snow, box, tray.
*/
 private final boolean cvc(int i) {
     if (i < 2 \mid | ! cons(i) \mid | cons(i - 1) \mid | ! cons(i - 2)) return false;
         int ch = b[i];
         if (ch == 'w' || ch == 'x' || ch == 'y') return false;
     return true;
 }
 private final boolean ends(String s) {
     int 1 = s.length();
     int 0 = k - 1 + 1;
     if (o < 0) return false;
     for (int i = 0; i < 1; i++) if (b[o + i] != s.charAt(i)) return false;
     j = k - 1;
     return true;
 }
/* setto(s) sets (j+1),...k to the characters in the string s, readjusting
   k. */
 private final void setto(String s) {
     int 1 = s.length();
     int 0 = j + 1;
     for (int i = 0; i < 1; i++) b[o + i] = s.charAt(i);
     k = j + 1;
 }
 /* r(s) is used further down. */
 private final void r(String s) {
     if (m() > 0) setto(s);
/* step1() gets rid of plurals and -ed or -ing. e.g.
       caresses -> caress
       ponies
                -> poni
                 -> ti
       ties
                -> caress
       caress
                 -> cat
       cats
```

```
feed
                -> feed
       agreed
                 -> agree
                -> disable
       disabled
      matting
                 -> mat
      mating
                 -> mate
      meeting
                -> meet
      milling
                 -> mill
      messing
                 -> mess
      meetings -> meet
*/
private final void step1() {
    if (b[k] == 's') {
         if (ends("sses")) k -= 2;
         else if (ends("ies")) setto("i");
         else if (b[k - 1] != 's') k--;
    if (ends("eed")) {
         if (m() > 0) k--;
     } else if ((ends("ed") || ends("ing")) && vowelinstem()) {
         k = j;
         if (ends("at")) setto("ate");
         else if (ends("bl")) setto("ble");
         else if (ends("iz")) setto("ize");
         else if (doublec(k)) {
            k--;
             {
                 int ch = b[k];
                 if (ch == '1' || ch == 's' || ch == 'z') k++;
         } else if (m() == 1 && cvc(k)) setto("e");
    }
}
/* step2() turns terminal y to i when there is another vowel in the stem. */
private final void step2() {
     if (ends("y") \&\& vowelinstem()) b[k] = 'i';
/* step3() maps double suffices to single ones. so -ization ( = -ize plus
   -ation) maps to -ize etc. note that the string before the suffix must give
   m() > 0. */
private final void step3() {
     if (k == 0) return; /* For Bug 1 */
    switch (b[k - 1]) {
         case 'a':
             if (ends("ational")) {
                 r("ate");
                 break;
             if (ends("tional")) {
                 r("tion");
                 break;
             }
```

```
break;
case 'c':
    if (ends("enci")) {
        r("ence");
        break;
    if (ends("anci")) {
        r("ance");
        break;
    break;
case 'e':
    if (ends("izer")) {
        r("ize");
        break;
    }
    break;
case '1':
    if (ends("bli")) {
        r("ble");
        break;
    }
    if (ends("alli")) {
        r("al");
        break;
    if (ends("entli")) {
        r("ent");
        break;
    if (ends("eli")) {
        r("e");
        break;
    if (ends("ousli")) {
        r("ous");
        break;
    }
   break;
case 'o':
    if (ends("ization")) {
        r("ize");
        break;
    if (ends("ation")) {
        r("ate");
        break;
    if (ends("ator")) {
        r("ate");
        break;
   break;
case 's':
    if (ends("alism")) {
        r("al");
        break;
    if (ends("iveness")) {
```

```
r("ive");
                break;
            if (ends("fulness")) {
                r("ful");
                break;
            if (ends("ousness")) {
                r("ous");
                break;
            break;
        case 't':
            if (ends("aliti")) {
                r("al");
                break;
            if (ends("iviti")) {
                r("ive");
                break;
            if (ends("biliti")) {
                r("ble");
                break;
            break;
        case 'g':
            if (ends("logi")) {
                r("log");
                break;
            }
    }
}
/* step4() deals with -ic-, -full, -ness etc. similar strategy to step3. */
private final void step4() {
    switch (b[k]) {
        case 'e':
            if (ends("icate")) {
                r("ic");
                break;
            }
            if (ends("ative")) {
                r("");
                break;
            if (ends("alize")) {
                r("al");
                break;
            break;
        case 'i':
            if (ends("iciti")) {
                r("ic");
                break;
            break;
        case '1':
```

```
if (ends("ical")) {
                r("ic");
                break;
            if (ends("ful")) {
                r("");
                break;
            break;
        case 's':
            if (ends("ness")) {
                r("");
                break;
            break;
    }
}
/* step5() takes off -ant, -ence etc., in context <c>vcvc<v>. */
private final void step5() {
    if (k == 0) return; /* for Bug 1 */
    switch (b[k - 1]) {
        case 'a':
            if (ends("al")) break;
            return;
        case 'c':
            if (ends("ance")) break;
            if (ends("ence")) break;
            return;
        case 'e':
            if (ends("er")) break;
            return;
        case 'i':
            if (ends("ic")) break;
            return;
        case '1':
            if (ends("able")) break;
            if (ends("ible")) break;
            return;
        case 'n':
            if (ends("ant")) break;
            if (ends("ement")) break;
            if (ends("ment")) break;
            /* element etc. not stripped before the m */
            if (ends("ent")) break;
            return;
        case 'o':
            if (ends("ion") \&\& j >= 0 \&\& (b[j] == 's' || b[j] == 't')) break;
            /* j >= 0 fixes Bug 2 */
            if (ends("ou")) break;
            return;
        /* takes care of -ous */
        case 's':
            if (ends("ism")) break;
            return;
        case 't':
            if (ends("ate")) break;
            if (ends("iti")) break;
```

```
return;
            case 'u':
                if (ends("ous")) break;
                return;
            case 'v':
                if (ends("ive")) break;
                return;
            case 'z':
                if (ends("ize")) break;
                return;
            default:
                return;
        if (m() > 1) k = j;
    }
    /* step6() removes a final -e if m() > 1. */
    private final void step6() {
        j = k;
        if (b[k] == 'e') {
            int a = m();
            if (a > 1 | | a == 1 && !cvc(k - 1)) k--;
        if (b[k] == '1' \&\& doublec(k) \&\& m() > 1) k--;
    }
    /**
     * Stem the word placed into the Stemmer buffer through calls to add().
     * Returns true if the stemming process resulted in a word different
     * from the input. You can retrieve the result with
     * getResultLength()/getResultBuffer() or toString().
    public void stem() {
        k = i - 1;
        if (k > 1) {
            step1();
            step2();
            step3();
            step4();
            step5();
            step6();
        i_end = k + 1;
        i = 0;
    }
}
```

:Tokenizer

```
package Indexer;
import java.util.ArrayList;
* @author brandonskane This class tokenizes, removes stop words and then uses
           the Porter Stemming Algorithm (via the Stemmer class) to stem words.
public class Tokenizer {
  ArrayList<String> allWords;
  ArrayList<String> stopWords;
  ArrayList<String> stemmedWords;
    * @param seperatedWords
                 the words from the input file. They are potentially dirty but
                 will be cleaned
    * @param stopWords
                 the stop words list. They must be properly formatted prior
   public Tokenizer(String[] seperatedWords, String[] stopWords) {
      this.allWords = new ArrayList<String>();
      this.stopWords = new ArrayList<String>();
      this.stemmedWords = new ArrayList<String>();
      tokenizer(seperatedWords);
      removeEmptyWords();
      System.out.println("Token");
      System.out.println(allWords);
      removeStopWords(stopWords);
      System.out.println("Remove Stop");
      System.out.println(allWords);
      stemWords();
   }
   public Tokenizer(ArrayList<String> seperatedWords, String[] stopWords) {
      this.allWords = new ArrayList<String>();
      this.stopWords = new ArrayList<String>();
      this.stemmedWords = new ArrayList<String>();
      tokenizer(seperatedWords);
      removeEmptyWords();
      System.out.println("Token");
     System.out.println(allWords);
      removeStopWords(stopWords);
     System.out.println("Remove Stop");
     System.out.println(allWords);
      stemWords();
   }
   * @return All of the final tokens from the stemmedWords list (the completed
              product)
   public String getProcessedWords() {
      StringBuilder stringBuilder = new StringBuilder();
```

```
for (String word : stemmedWords) {
      stringBuilder.append(word + " ");
   }
   return stringBuilder.toString();
}
/**
 * The Stemmer class requires words to be build via chars. Go through each
 * word in the the allWords array and create Stemmer objects Then convert
 * back to a String and add to stemmedWords (final product state)
private void stemWords() {
   char[] wordCharArray;
   Stemmer s = new Stemmer();
   for (String word : allWords) {
      wordCharArray = word.toCharArray();
      for (int i = 0; i < word.length(); i++) {</pre>
         s.add(wordCharArray[i]);
      s.stem(); // call to "stem" the word
      stemmedWords.add(s.toString());
   }
}
 * Clean the words -- remove paragraphs, split hyphens and remove links
 * @param seperatedWords
              the raw words from the input file
private void tokenizer(String[] seperatedWords) {
   for (String word : seperatedWords) {
      word = word.replace("\r", "");
word = word.replace("\n", "");
      if (word.length() != 0 && !word.isEmpty() && !word.equals(" ")
            && !word.equals("")) {
         if (word.contains("http://") || word.contains("www.")) {
            processURL(word);
         } else {
            if (word.contains("-")) {
               String[] splitWords = splitHyphenWord(word);
               for (String string : splitWords) {
                   allWords.add(cleanString(string));
               }
            } else {
               allWords.add(cleanString(word));
            }
         }
      }
   }
   finalPassToSplitWordsWithAttachedNumbers();
}
```

```
private void tokenizer(ArrayList<String> seperatedWords) {
   for (String word : seperatedWords) {
      word = word.replace("\r", "");
word = word.replace("\n", "");
      if (word.length() != 0 && !word.isEmpty() && !word.equals(" ")
            && !word.equals("")) {
         if (word.contains("http://") || word.contains("www.")) {
            processURL(word);
         } else {
            if (word.contains("-")) {
               String[] splitWords = splitHyphenWord(word);
               for (String string : splitWords) {
                   allWords.add(cleanString(string));
               }
            } else {
               allWords.add(cleanString(word));
         }
      }
   }
   //finalPassToSplitWordsWithAttachedNumbers();
}
 st If a number has been attached to a word, it must be separated. The
 ^{st} separated word is inserted, in order, into allWords
private void finalPassToSplitWordsWithAttachedNumbers() {
   // add(int index, E element)
   for (int i = 0; i < allWords.size(); i++) {</pre>
      String wordToTest = allWords.get(i);
      int index = containsLettersAndNumbers(wordToTest);
      if (index >= 0) { //if less than 0, no digit was found
            String[] word = allWords.get(i).split(
                   "(?<=\\D)(?=\\d)|(?<=\\d)(?=\\D)");
            allWords.set(i, word[0]);
            allWords.add(i + 1, word[1]);
         }
      }
   }
}
* This is a helper method for finalPassToRemoveAnyAttachedNumbers()
   @param wordToTest
              A candidate word to split by a digit
   @return The index of the digit (where to split)
private int containsLettersAndNumbers(String wordToTest) {
   ArrayList<Integer> indexes = new ArrayList<Integer>();
   boolean letterFound = false;
```

```
for (int i = 0; i < wordToTest.length(); i++) {</pre>
      if (!Character.isLetter(wordToTest.charAt(i))) {
         indexes.add(i);
      }
      if (Character.isLetter(wordToTest.charAt(i))) {
         letterFound = true;
      }
   }
   if (!indexes.isEmpty() && letterFound) {
      return indexes.get(0);
   return -1;
}
private void processURL(String URL) {
   URL = URL.replaceAll("\\W", " ");
URL = URL.replaceAll("_", " ");
   String[] URLs = URL.split(" ");
   for (String string : URLs) {
      if (string.length() != 0)
         allWords.add(cleanString(string));
   }
}
 * Removes all instances of stop words from the allWords array
   @param stopWords
               the stop words from the stopWord input file
private void removeStopWords(String[] stopWords) {
   for (String string : stopWords) {
      this.stopWords.add(string);
   }
   for (int j = 0; j < stopWords.length; j++) {</pre>
      for (int i = 0; i < allWords.size(); i++) {</pre>
         if (allWords.get(i).equals(this.stopWords.get(j))) {
             allWords.remove(i);
      }
   }
}
 * @param word
              a "word" containing a hyphen to be split
   @return an array of 2 words after being split from the array
private String[] splitHyphenWord(String word) {
   String[] splitWords = null;
```

```
if (word.contains("-")) {
         splitWords = word.split("-");
      return splitWords;
   }
   * Using regex, remove numbers and non-alphanumeric chars, make lower case
   * and remove trailing spaces
    * @param word
                 the word to "clean"
    * @return a "cleaned" word
   private String cleanString(String word) {
      // word = word.replaceAll("[0-9]", "");
      word = word.replaceAll("\\W", "");
      return word.toLowerCase().trim();
   }
   /**
   * If any empty words have made it into the list this will remove them
   private void removeEmptyWords() {
      for (int i = 0; i < allWords.size(); i++) {</pre>
         if (allWords.get(i).length() == 0) {
            allWords.remove(i);
         }
      }
   }
}
```

کلاس EnglishStopWords:

```
public class EnglishStopWords {
   public static String[] stopWords = { "a", "about", "above", "after", "again",
"mustn't", "my", "myself", "needn", "needn't", "no", "nor", "not",
"then", "there", "these", "they", "this",

"those", "through", "to", "too", "under", "until", "up", "ve", "very",
"was", "wasn", "wasn't", "we",
"were", "weren", "weren't", "what", "when", "where", "which", "while", "who", "why", "will", "with",
"won", "won't", "wouldn", "wouldn't", "y", "you", "you'd", "you'll", "you're", "you've", "your", "yours",
          "yourself", "yourselves", "could", "he'd", "he'll", "he's", "here's",
"added", "adj", "affected",
         "affecting", "affects", "afterwards", "ah", "almost", "alone",
"along", "already", "also", "although",
"arent", "arise", "around", "aside", "ask",
"asking", "auth", "available", "away", "awfully", "b", "back", "became", "becomes", "becoming",
         "beforehand", "begin", "beginning", "beginnings", "begins", "behind",
"believe", "beside", "besides",
         "beyond", "biol", "brief", "briefly", "c", "ca", "came", "cannot",
"can't", "cause", "causes", "certain",

"certainly", "co", "come", "comes", "contain", "containing",
         "couldnt", "date",
"contains",
         "different", "done", "downwards", "due", "e", "ed", "edu", "effect",
"eg", "eight", "eighty", "either",
         ", "eighty", "either",
"else", "elsewhere", "end", "ending", "enough", "especially", "et",
"etc", "even", "ever", "every",
          "everybody", "everyone", "everything", "everywhere", "ex", "except",
"f", "far", "ff", "fifth", "first",
```

```
"five", "fix", "followed", "following", "follows", "former",
             "forth", "found", "four",
"formerly",
             "furthermore", "g", "gave", "get", "gets", "getting", "give", "given",
"gives", "giving", "go", "goes",
              "gone", "got", "gotten", "h", "happens", "hardly", "hed", "hence",
"however", "hundred", "id", "ie", "im",
"immediate", "immediately", "importance", "important", "inc",
"mainly", "make", "makes", "many", "may", "maybe", "mean", "means",
"meantime", "meanwhile", "merely", "mg",
             "might", "million", "miss", "ml", "moreover", "mostly", "mr", "mrs",
"much", "mug", "must", "n", "na",
"name", "namely", "nay", "nd", "near", "nearly", "necessarily",
"necessary", "need", "needs", "neither",
"never", "nevertheless", "new", "next", "nine", "ninety", "nobody",
"okay", "old", "omitted", "one", "ones", "onto", "ord", "others",
"otherwise", "outside", "overall",

"owing", "p", "page", "pages", "part", "particular", "particularly",

"past", "per", "perhaps", "placed",
"please", "plus", "poorly", "possible", "possibly", "potentially",
"pp", "predominantly", "present",
"previously", "primarily", "probably", "promptly", "proud",

"provides", "put", "q", "que", "quickly",

"quite", "qv", "r", "ran", "rather", "rd", "readily", "really",

"recent", "recently", "refs", "refs",
             "regarding", "regardless", "regards", "related", "relatively",
"research", "respectively", "resulted",
"resulting", "results", "right", "run", "said", "saw", "say", "saying", "says", "sec", "section", "see",
              "seeing", "seem", "seemed", "seeming", "seems", "seen", "self",
"selves", "sent", "seven", "several",

"shall", "shed", "shes", "show", "showed", "shown", "showns", "shows",
"significant", "significantly",
"similar", "similarly", "since", "six", "slightly", "somebody", "somehow", "someone", "somethan",
"substantially", "successfully",
              "sufficiently", "suggest", "sup", "sure", "take", "taken", "taking",
"tell", "tends", "th", "thank",

"thanks", "thanx", "thats", "that've", "thence", "thereafter",

"thereby", "thered", "therefore", "therein",

"there'll", "thereof", "therere", "theres", "thereto", "thereupon",
             "theyd", "theyre", "think",
"there've",
"thou", "though", "thoughh", "thousand", "throug", "throughout",
"thru", "thus", "til", "tip", "together",
"took", "toward", "towards", "tried", "tries", "truly", "try",
```

```
"trying", "ts", "twice", "two", "u", "un",
                         "unfortunately", "unless", "unlike", "unlikely", "unto", "upon",
"ups", "us", "use", "used", "useful", "useful", "usefully", "usefulness", "uses", "using", "usually", "v", "value",
"various", "'ve", "via", "viz", "vol",
                         "vols", "vs", "w", "want", "wants", "wasnt", "way", "wed", "welcome",
"went", "werent", "whatever",
                         "what'll", "whats", "whence", "whenever", "whereafter", "whereas",
"whereby", "wherein", "wheres",
                         "whereupon", "wherever", "whether", "whim", "whither", "whod",
"whoever", "whole", "who'll", "whoméver",
"whos", "whose", "widely", "willing", "wish", "within", "without",
"c'mon", "c's", "cant", "changes", "clearly", "concerning", "consequently", "consider", "considering",
"second", "secondly", "sensible", "serious",

"seriously", "sure", "t's", "third", "thorough", "thoroughly",

"three", "well", "wonder", "a", "about",

"above", "above", "across", "after", "afterwards", "again", "against",
"all", "almost", "alone", "along",
                         "already", "also", "although", "always", "am", "among", "amongst",
"amoungst", "amount", "an", "and",
                        "another", "any", "anyhow", "anyone", "anything", "anyway",
"are", "around", "as", "at", "back",
"be", "became", "because", "become", "becomes", "becoming", "been",
"anywhere",
"before", "beforehand", "behind",
"being", "below", "beside", "besides", "between", "beyond", "bill",

"both", "bottom", "but", "by", "call",

"can", "cannot", "cant", "co", "con", "could", "couldnt", "cry", "de",

"describe", "detail", "do", "done",

"down", "due", "during", "each", "eg", "eight", "either", "eleven",

"else", "elsewhere", "empty", "enough",

"ate" "oven" "oven" "oven" "oven" "oven ""oven ""ove
"etc", "even", "ever", "every", "everyone", "everything",

"everywhere", "except", "few", "fifteen", "fify",

"fill", "find", "fire", "first", "five", "for", "former", "formerly",

"forty", "four", "four", "from",
                         "front", "full", "further", "get", "give", "go", "had", "has",
"hasnt", "have", "he", "hence", "hereby", "herein", "hereupon", "hers",
"herself", "him", "himself", "his", "how",
"however", "hundred", "ie", "if", "in", "inc", "indeed", "interest",
"name", "namely", "neither", "never", "nevertheless", "next", "nine",
"no", "nobody", "none", "noone",
                         "nor", "not", "nothing", "now", "nowhere", "of", "off", "often", "on",
"once", "one", "only", "onto", "or",
```

```
"other", "others", "otherwise", "our", "ours", "ourselves", "out",
"over", "own", "part", "per", "perhaps",

"please", "put", "rather", "re", "same", "see", "seem", "seemed",
                  "seems", "serious", "several",
"she", "should", "show", "side", "since", "sincere", "six", "sixty",
"seeming",
"so", "some", "somehow", "someone",

"something", "sometime", "sometimes", "somewhere", "still", "such",
"system", "take", "ten", "than", "that",
                   "the", "their", "them", "themselves", "then", "thence", "there",
                   ', "thereby", "therefore",
"therein", "thereupon", "these", "they", "thickv", "thin", "third",
"thereafter"
"this", "those", "though", "three",
                   "through", "throughout", "thru", "thus", "to", "together", "too",
"top", "toward", "towards", "twelve",

"twenty", "two", "un", "under", "until", "up", "upon", "us", "very",

"via", "was", "we", "well", "were",

"what", "whatever", "when", "whence", "whenever", "where",
"whereafter", "whereas", "whereby", "wherein",
"whereupon", "wherever", "whether", "which", "while", "whither",
"who", "whoever", "whole", "whom", "whose",

"why", "will", "with", "within", "without", "would", "yet", "you",
"your", "yours", "yourself"
               "yourselves", "the", "a", "b", "c", "d", "e", "f", "g", "h", "i", "j", "m", "n", "o", "p", "q", "r", "s", "t", "u", "v", "w", "x", "y", "z", "A", "B", "C", "D", "E", "H", "I", "J", "K", "L",
"k", "1",
"F", "G",
                   "M", "N", "O", "P", "Q", "R", "S", "T", "U", "V", "W", "X", "Y", "Z",
"co", "op",
                   "research-articl",
                   "pagecount", "cit", "ibid", "les", "le", "au", "que", "est", "pas", "los", "pp", "u201d",
                   "well-b", "http", "volumtype", "par", "00", "0s", "3a", "3b", "3d",
                   "a1", "a2", "a3", "a4", "ab", "ac", "ad", "ae", "af", "ag", "aj", "al", "an", "ao", "ap",
"6b", "60",
                   "aw", "ax", "ay", "az", "b1", "b2", "b3", "ba", "bc", "bd", "be", "bi", "bj", "bk", "bl", "bn",
         "av",
                   "b2", "b3", "ba", "bc", "bd", "be", "bi", "bj", "bk", "bl", "bn", "bs", "bt", "bu", "c1", "c2", "c3", "cc", "cd", "ce", "cf", "cg", "ch", "ci", "cj", "c1", "cp", "cq", "cr", "cs", "ct", "cu", "cv", "cx", "cy", "cz", "d2", "da", "dc", "dd", "de", "df", "dk", "dl", "do", "dp", "dr", "ds", "dt", "du", "dx", "dy", "e2", "e3", "ea", "ec", "ed", "ee", "ej", "el", "em", "en", "eo", "ev", "ex", "ey", "f2", "fa", "fi" "fi" "fi" "fn" "fo"
"bp", "br",
"cm", "cn",
"di", "dj",
"ef", "ei",
                   "fi", "fj", "fl", "fn", "fo",
"fr", "fs", "ft", "fu", "fy", "ga", "ge", "gi", "gj", "gl", "go",
"gy", "h2", "h3", "hh", "hi",
"hj", "ho", "hr", "hs", "hu", "hy", "i", "i2", "i3", "i4", "i6", "i7",
"fc", "ff",
"gr", "gs",
                   "ib", "ic", "ie", "ig",
"i8", "ia",
                   "ih", "ii", "ij",
"ij", "jr", "js",
" "'i"
                                     "ij", "il",
"js", "jt",
                                                         "in", "io", "ip", "iq", "ir", "iv", "ix",
                                                         "ju",
        "iz",
                   "ke",
                             "kg",
                                      "kj",
                                                "km",
                                                          "ko", "12", "la", "lb", "lc", "lf", "lj",
                                      "1ť",
                   "lr",
                             "ls",
                                                          "ml",
                                                "m2",
"ln", "lo",
                   "mn",
                             "mo",
                                      "ms",
                                                "mt",
                                                          "mu", "n2", "nc", "nd", "ne", "ng", "ni",
                                      "ns",
                                                         "ny",
                   "nn",
                             "nr",
                                                "nt",
"nj", "nl",
                             "ob",
                                      "oc",
                                                "od",
                                                          "of", "og", "oi", "oj", "ol", "om", "on",
                   "oa",
                   "or", "os", "ot", "ou", "ow",
"ox", "oz", "p1", "p2", "p3", "pc", "pd", "pe", "pf", "ph", "pi",
"p1", "pm", "pn", "po", "pq",
"pr", "ps", "pt", "pu", "py", "qj", "qu", "r2", "ra", "rc", "rd",
         "oq",
"pj", "pk",
```

:DataAccess

```
package Indexer;
import java.sql.*;
public class DataAccess {
    private static DataAccess access;
    private PreparedStatement getRightUrlsStatement;
    private PreparedStatement[] resetIndexingTablesStatements;
    private PreparedStatement getUrlIdStatement;
    private PreparedStatement insertDocSizeStatement;
    private PreparedStatement findWordIdStatement;
    private PreparedStatement isAlreadyWordAddedToUrlStatement;
    private PreparedStatement increaseWordFreqStatement;
    private PreparedStatement addWordStatement;
    private PreparedStatement addWord2Statement;
    PreparedStatement isAlreadyInsertedInDocSizeStatement;
    private DataAccess() throws SQLException {
        init();
    }
    public static Connection getConnection() {
        Connection connection = null;
        try {
            Class.forName("com.mysql.jdbc.Driver");
            connection = DriverManager.getConnection(
                    "jdbc:mysql://localhost:3306/search_engine", "root", "");
        } catch (Exception e) {
            e.printStackTrace();
        }
        return connection;
    }
    public static DataAccess getAccess() throws SQLException {
        if (access == null) {
            access = new DataAccess();
        return access;
    }
    private void init() throws SQLException {
        Connection dbConnection = getConnection();
        getRightUrlsStatement = dbConnection.prepareStatement("SELECT * FROM urls
WHERE is_index=TRUE;");
        resetIndexingTablesStatements = new PreparedStatement[]{
                dbConnection.prepareStatement("DELETE FROM words;"),
                dbConnection.prepareStatement("ALTER TABLE words AUTO INCREMENT =
1;"),
                dbConnection.prepareStatement("DELETE FROM word_doc;"),
                dbConnection.prepareStatement("ALTER TABLE word_doc AUTO_INCREMENT
= 1;"),
                dbConnection.prepareStatement("DELETE FROM doc_size;"),
                dbConnection.prepareStatement("ALTER TABLE doc_size AUTO_INCREMENT
= 1;")
        };
        getUrlIdStatement = dbConnection.prepareStatement("SELECT id FROM urls
```

```
WHERE url=?;");
        insertDocSizeStatement = dbConnection.prepareStatement("INSERT INTO
doc_size (doc_url_id, doc_size) VALUES (?,?)");
       findWordIdStatement = dbConnection.prepareStatement("SELECT id FROM words
WHERE word=?;");
        isAlreadyWordAddedToUrlStatement = dbConnection.prepareStatement("SELECT
id FROM word_doc WHERE word_id=? AND doc_url_id=?");
        increaseWordFregStatement = dbConnection.prepareStatement("UPDATE word doc
SET freq=freq+1 WHERE doc url id=? AND word id=?");
        addWordStatement = dbConnection.prepareStatement("INSERT INTO words (word)
VALUES (?);");
        addWord2Statement = dbConnection.prepareStatement("INSERT INTO word_doc
(word_id, doc_url_id, freq) VALUES (?,?,?);");
        isAlreadyInsertedInDocSizeStatement =
dbConnection.prepareStatement("SELECT * FROM doc_size WHERE doc_url_id=?");
   }
    public void resetIndexingTables() throws SQLException {
        executeMultiStatement(resetIndexingTablesStatements);
   private void executeMultiStatement(PreparedStatement[] preparedStatements)
throws SQLException {
       for (PreparedStatement preparedStatements) {
            preparedStatement.execute();
    }
   public ResultSet getRightUrls() throws SQLException {
        return getRightUrlsStatement.executeQuery();
    }
   public long getID(String url) throws SQLException {
        getUrlIdStatement.setString(1, url);
       ResultSet resultSet = getUrlIdStatement.executeQuery();
        resultSet.first();
       return resultSet.getLong("id");
    }
   public boolean insertDocSize(long docUrlId, long docSize) throws SQLException
{
        insertDocSizeStatement.setLong(1, docUrlId);
        insertDocSizeStatement.setLong(2, docSize);
        return insertDocSizeStatement.executeUpdate() > 0;
    }
    public boolean isWordAlreadyExisting(String word) throws SQLException {
        findWordIdStatement.setString(1, word);
        return findWordIdStatement.executeQuery().next();
    }
    public long getWordId(String word) throws SQLException {
        findWordIdStatement.setString(1, word);
        ResultSet resultSet = findWordIdStatement.executeQuery();
        resultSet.first();
       return resultSet.getLong("id");
    }
    public boolean isAlreadyWordAddedToUrl(long wordId, long docUrlID) throws
```

```
SQLException {
        isAlreadyWordAddedToUrlStatement.setLong(1, wordId);
        isAlreadyWordAddedToUrlStatement.setLong(2, docUrlID);
        return isAlreadyWordAddedToUrlStatement.executeQuery().next();
    }
    public boolean increaseWordFreq(long docUrlId, long wordId) throws
SQLException {
        increaseWordFreqStatement.setLong(1, docUrlId);
        increaseWordFreqStatement.setLong(2, wordId);
        return increaseWordFreqStatement.executeUpdate() > 0;
    }
    public boolean addWord(String word) throws SQLException {
        addWordStatement.setString(1, word);
        return addWordStatement.execute();
    }
    public boolean addWord2(long wordId, long docUrlId, long freq) throws
SQLException {
        addWord2Statement.setLong(1, wordId);
        addWord2Statement.setLong(2, docUrlId);
        addWord2Statement.setLong(3, freq);
        return addWord2Statement.execute();
    }
    public boolean isAlreadyInsertedInDocSize(long docUrlId) throws SQLException {
        isAlreadyInsertedInDocSizeStatement.setLong(1, docUrlId);
        return isAlreadyInsertedInDocSizeStatement.executeQuery().next();
    }
}
```

كلاس lutill :

```
package Indexer;
import java.io.BufferedReader;
import java.io.IOException;
import java.io.InputStreamReader;
import java.net.URL;
import java.net.URLConnection;
import java.util.ArrayList;
public class utill {
    public static void writeALine() {
        System.out.println("----");
    public static ArrayList<String> textToWordsList(String text) {
        String[] words = text.split("[\\s/(,='-]");
        ArrayList<String> arrayList = new ArrayList<>();
        for (String item : words) {
            if (!(item.equals(""))) arrayList.add(item);
        return arrayList;
    public static String getUrlHtml(String url) {
        StringBuilder stringBuilder = new StringBuilder();
            URL theUrl = new URL(url);
            URLConnection conn = theUrl.openConnection();
            BufferedReader br = new BufferedReader(
                    new InputStreamReader(conn.getInputStream()));
            String inputLine;
            while ((inputLine = br.readLine()) != null) {
                stringBuilder.append(inputLine);
            br.close();
        } catch (Exception ignored) {
        return stringBuilder.toString();
    }
}
```

بخش رتبه بندی

روش Tfldf

در این روش رتبه ی لینک ها بر اساس پارامترهای تعداد یک کلمه ی خاص در یک لینک و همه ی لینک ها و تعداد کل لینک به دست میآید.

$$w_{i,j} = tf_{i,j} imes \log(\frac{N}{df_i})$$
 : Tfldf رابطهی $tf_{ij} = \text{number of occurrences of } i \text{ in } j$
 $df_i = \text{number of documents containing } i$
 $N = \text{total number of documents}$

رتبه بندی از طریق این روش در این پروژه با استفاده از دو کلاس Tfldf و DataAccess انجام شده است که هر یک از آنها به ترتیب مورد بررسی قرار میگیرند.

کلاس Tfldf : در این کلاس با داشتن ورودیهای شماره های id کلمه و url میتوان رتبه مربوط به آن url به ازای یک کلمه را محاسبه کرد. این محاسبه از طریق متدهای tf و idf انجام میشود. پس از محاسبه این دو پارامتر در متد سازنده این کلاس محاسبه tf_idf انجام می گردد و در جدول tf_idf دیتابیس ذخیره میگردد.

کلاس DataAccess : در این کلاس توسط متد getConnection، یک آبجکت از کلاس Connection ایجاد می شود. این کلاس مسئولیت برقراری ارتباط نرم افزار جاوا با دیتابیس MySQL را بر عهده دارد. کوئری های موردنیاز جهت انجام متدهای مربوط به ranking با روش tf_idf ابتدا در متغیرهای PreparedStatement ذخیره و سپس با متد excute اجرا میشوند.

کلاس Tfldf:

```
package Ranker.TfIdf;
import java.sql.ResultSet;
import java.sql.SQLException;
public class TfIdf {
    private DataAccess dataAccess;
    private long docsSize;
    private long urlId;
    private long wordId;
    private double tfIdf;
    private TfIdf(long urlId, long wordId) throws SQLException,
ClassNotFoundException {
        this.dataAccess = DataAccess.getAccess();
        this.urlId = urlId;
        this.wordId = wordId;
        this.docsSize = dataAccess.getDocsSize();
        tfIdf = tf() * idf();
    }
    public static TfIdf getInstance(long urlId, long wordId) throws SQLException,
ClassNotFoundException {
        return new TfIdf(urlId, wordId);
    }
    public static void start() throws SQLException, ClassNotFoundException {
        TfIdf tfIdf;
        DataAccess dataAccess = DataAccess.getAccess();
        ResultSet resultSet = dataAccess.getRightUrlIds();
        resultSet.first();
        ResultSet urlWordIdsResultSet;
        while(true){
            if (resultSet.next()) {
                do {
                    long urlId = resultSet.getLong("id");
                    urlWordIdsResultSet = dataAccess.getUrlWordIds(urlId);
                    urlWordIdsResultSet.first();
                    if (urlWordIdsResultSet.next()) {
                        do {
                            long wordId = urlWordIdsResultSet.getLong("word_id");
                            tfIdf = TfIdf.getInstance(urlId, wordId);
                            tfIdf.rank();
                            System.out.println("new ranking submitted -> url_id: "
+ urlId + "\nword_id: " + wordId + "\n\n");
                        } while (urlWordIdsResultSet.next());
                } while (resultSet.next());
            }
        }
    }
    public void rank() throws SQLException {
        dataAccess.insertTfId(tfIdf, urlId, wordId);
    public double tf() throws SQLException {
```

```
long wordFreq = dataAccess.getWordFreq(wordId, urlId);
long docSize = dataAccess.getDocSizeByUrlId(urlId);
return (double) wordFreq / docSize;
}

public double idf() throws SQLException {
   long wordFreqInAllDocs = dataAccess.getWordFreqInAllDocs(wordId);
   return Math.log(docsSize / wordFreqInAllDocs);
}
```

: DataAccess

```
package Ranker.TfIdf;
import java.sql.*;
public class DataAccess {
    private static DataAccess access;
    private PreparedStatement insertTfIdfStatement;
    private PreparedStatement getDocsSizeStatement;
    private PreparedStatement findWordFreqStatement;
    private PreparedStatement getDocSizeByUrlIdStatement;
    private PreparedStatement getWordFreqInAllDocsStatement;
    private PreparedStatement getRightUrlIdsStatement;
    private PreparedStatement getUrlWordIdsStatement;
    private PreparedStatement[] resetTfIdfTableStatements;
    private DataAccess() throws SQLException {
        init();
    public static Connection getConnection() {
        Connection connection = null;
        try {
            Class.forName("com.mysql.jdbc.Driver");
            connection = DriverManager.getConnection(
                    "jdbc:mysql://localhost:3306/search_engine", "root", "");
        } catch (Exception e) {
            e.printStackTrace();
        return connection;
    }
    public static DataAccess getAccess() throws SQLException,
ClassNotFoundException {
        if (access == null) {
            access = new DataAccess();
        return access;
    }
    private void init() throws SQLException {
        Connection dbConnection = getConnection();
        getDocsSizeStatement = dbConnection.prepareStatement("SELECT COUNT(*) as c
from urls");
        insertTfIdfStatement = dbConnection.prepareStatement("INSERT INTO tf idf
(score, doc_url_id, word_id) VALUES (?,?,?)");
        findWordFreqStatement = dbConnection.prepareStatement("SELECT freq FROM
word doc WHERE word id=? AND doc url id=?;");
        getDocSizeByUrlIdStatement = dbConnection.prepareStatement("SELECT
doc_size FROM doc_size WHERE doc_url_id=?");
        getWordFreqInAllDocsStatement = dbConnection.prepareStatement("SELECT
COUNT(*) AS c FROM word_doc WHERE word_id=?");
        getRightUrlIdsStatement = dbConnection.prepareStatement("SELECT id FROM
urls WHERE is_index=TRUE");
        getUrlWordIdsStatement = dbConnection.prepareStatement("SELECT word_id
FROM word_doc WHERE doc_url_id=?");
```

```
resetTfIdfTableStatements = new PreparedStatement[]{
                dbConnection.prepareStatement("DELETE FROM tf idf;"),
                dbConnection.prepareStatement("ALTER TABLE tf_idf
AUTO INCREMENT=1")
        };
    }
    public long getDocsSize() throws SQLException {
        ResultSet resultSet = getDocsSizeStatement.executeQuery();
        resultSet.first();
        return resultSet.getLong("c");
    }
    public boolean insertTfId(double score, long docUrlId, long wordId) throws
SQLException {
        insertTfIdfStatement.setDouble(1, score);
        insertTfIdfStatement.setLong(2, docUrlId);
        insertTfIdfStatement.setLong(3, wordId);
        return insertTfIdfStatement.execute();
    }
    public long getWordFreq(long wordId, long docUrlId) throws SQLException {
        findWordFreqStatement.setLong(1, wordId);
        findWordFreqStatement.setLong(2, docUrlId);
        ResultSet resultSet = findWordFreqStatement.executeQuery();
        resultSet.first();
        return resultSet.getLong("freq");
    }
    public long getDocSizeByUrlId(long docUrlId) throws SQLException {
        getDocSizeByUrlIdStatement.setLong(1, docUrlId);
        ResultSet resultSet = getDocSizeByUrlIdStatement.executeQuery();
        resultSet.first();
        return resultSet.getLong("doc_size");
    }
    public long getWordFreqInAllDocs(long wordId) throws SQLException {
        getWordFreqInAllDocsStatement.setLong(1, wordId);
        ResultSet resultSet = getWordFreqInAllDocsStatement.executeQuery();
        resultSet.first();
        return resultSet.getLong("c");
    }
    public ResultSet getRightUrlIds() throws SQLException {
        return getRightUrlIdsStatement.executeQuery();
    public ResultSet getUrlWordIds(long docUrlId) throws SQLException {
        getUrlWordIdsStatement.setLong(1, docUrlId);
        return getUrlWordIdsStatement.executeQuery();
    public void resetTfIdfTable() throws SQLException {
        executeMultiStatement(resetTfIdfTableStatements);
    private void executeMultiStatement(PreparedStatement[] preparedStatements)
throws SQLException {
        for (PreparedStatement preparedStatement : preparedStatements) {
```

```
preparedStatement.execute();
}
}
```

روش PageRank:

در این روش رتبه بندی بر اساس پارامتر PageRank محاسبه میشود. این پارامتر نشان دهنده میزات اعتبار یک لینک بر اساس تعداد مرتبه هایی که به آن در لینک های دیگر آدرس داده شده است. این پارامتر بر اساس رابطه ی ذیل محاسبه میگردد.

$$PageRank \ of \ site = \sum \frac{PageRank \ of \ inbound \ link}{Number \ of \ links \ on \ that \ page}$$

OR

$$PR(u) = (1 - d) + d \times \sum \frac{PR(v)}{N(v)}$$

کلاس PageRank: در این کلاس محاسبه pagerank هر یک از url ها با استفاده از متد PageRank: در این کلاس raitizlize هر یک از url های خروجی اجرا می شود. این متد بر اساس اطلاعات طول اجرای این متد، متد initizlize جهت مقداردهی تعداد لینک های خروجی اجرا می شود. این متد بر اساس اطلاعات جدول links در در در در در از داشته اند. همچنین محاسبه می کند که هر یک از لینک های دیگر آدرس داده شده اند. مجموعه ی این اطلاعات در متد می گردد که هر یک از لینک ها چند با توسط لینک های دیگر آدرس داده شده اند. مجموعه ی این اطلاعات در متد calculate محاسبه امتیاز pagerank را موجب می شود. متد start در یک حلقه ی بی نهایت امتیاز pagerank لینک های موجود در جدول urls را محاسبه و در جدول pagerank ثبت می کند.

کلاس DataAccess : در این کلاس توسط متد getConnection، یک آبجکت از کلاس Connection ایجاد می شود. این کلاس مسئولیت برقراری ارتباط نرم افزار جاوا با دیتابیس MySQL را بر عهده دارد. کوئری های موردنیاز جهت انجام متدهای مربوط به ranking با روش pagerank ابتدا در متغیرهای PreparedStatement ذخیره و سپس با متد اجرا میشوند.

: Pagerank کلاس

```
package Ranker.PageRank;
import java.sql.ResultSet;
import java.sql.SQLException;
public class PageRank {
    private static final double COMPARE_DELTA = 0.0001;
    private static final double DAMPING_FACTOR = 0.9;
    private static final boolean IS CALCULATION DAMPED = true;
    private DataAccess dbAccess;
    private Double equalDistributionValue;
    private long startId, endId;
    connect to database and initialize vektor of every node with 1/amountOfNodes
    public PageRank(long startId, long endId) throws SQLException,
ClassNotFoundException {
        this.startId = startId;
        this.endId = endId;
        dbAccess = DataAccess.getAccess();
        initialize();
    }
    public static PageRank getInstance(long startId, long endId) throws
SQLException, ClassNotFoundException {
        return new PageRank(startId, endId);
    }
    public static void start(long limit) throws SQLException,
ClassNotFoundException {
        DataAccess dataAccess = DataAccess.getAccess();
        dataAccess.resetPageRankTable();
        long startId, endId;
        int i = 0;
        while (true) {
            int chapter = i + 1;
            System.out.println("PageRanker (chapter " + chapter + ") : started!");
            System.out.println("PageRanker (chapter " + chapter + ") : loading
...");
            startId = i * limit;
            endId = (i + 1) * limit;
                getInstance(startId, endId).calculatePageRank();
            } catch (Exception ignored) {
            System.out.println("PageRanker (chapter " + chapter + ") :
finished!");
            i++;
        }
    }
    set every vektor at the beginning of the calculation to initial value which is
1/amountOfNodes
    */
    private void initializeVector() throws SQLException {
```

```
dbAccess.initVektor(getEqualDistributionVektorValue(), startId, endId);
    }
    private void initialize() throws SQLException {
        ResultSet resultSet = dbAccess.getUrls(startId, endId);
        resultSet.first();
        if (resultSet.next()) {
            do {
                long docUrlID = resultSet.getLong("id");
                dbAccess.insertUrl(docUrlID);
                initializeVector();
                int amountOutgoingLinks = getOutgoingLinksCount(docUrlID);
                dbAccess.setOutgoingLinksValue(amountOutgoingLinks, docUrlID,
startId, endId);
            } while (resultSet.next());
        }
    }
    looping calculation while pagerank != vektor, every loop is headed by setting
vektor = pagerank and pagerank = 0
    public void calculatePageRank() throws SQLException {
        calculate();
        while (!isCalculationFinished()) {
            //System.out.println(dbAccess.getVektorSum());
            prepareNextRound();
            calculate();
        }
    }
    /*
    count amount of nodes
    public long getAmountOfNodes() throws SQLException {
          return dbAccess.getNodesCount(limit);
        return endId - startId;
    }
    iterate over all nodes, calculate increasing value by dividing vektor by the
amount of outgoing links and
    increase the pagerank value of the nodes of the outgoing links
    public void calculate() throws SQLException {
        ResultSet nodes = dbAccess.getPageRankTable(startId, endId);
        while (nodes.next()) {
            int id = nodes.getInt("doc_url_id");
            double vektor = nodes.getDouble("vektor");
            int outgoingLinksCount = nodes.getInt("outgoing");
            double increasingValue = vektor / outgoingLinksCount;
            increaseOutgoingLinksByValue(id, increasingValue);
        if (isCalculationDamped()) dampPageRank();
    }
    private void dampPageRank() throws SQLException {
        dbAccess.dampPageRank(DAMPING_FACTOR, equalDistributionValue, startId,
endId);
```

```
}
    /*
    get amount of outgoing links for the specified sourceId
    private int getOutgoingLinksCount(long sourceId) throws SQLException {
        return dbAccess.countOutgoingLinks(sourceId);
    }
    get all outgoing links and increase the value of the Pagerank of the connected
nodes
    private void increaseOutgoingLinksByValue(int sourceId, double value) throws
SQLException {
        ResultSet outgoingLink = dbAccess.getOutgoingLinks(sourceId);
        while (outgoingLink.next()) {
            int targetId = outgoingLink.getInt("target");
            increasePagerankByValue(targetId, value);
        }
    }
    increases the pageranke of a specified node by the given value
    private void increasePagerankByValue(int targetId, double increasingValue)
throws SQLException {
        dbAccess.increasePageRank(increasingValue, targetId, startId, endId);
    }
    /*
    prepare the next calculation round by setting vektor to pagerank and pagerank
to 0
    private void prepareNextRound() throws SQLException {
        dbAccess.prepareCalculation(startId, endId);
    private boolean isCalculationDamped() {
        return IS_CALCULATION_DAMPED;
    }
    check every node if the vektor and pagerank are similar, if not it returns
false by the first node which dont fit
    private boolean isCalculationFinished() throws SQLException {
        ResultSet node = dbAccess.getPageRankTable(startId, endId);
        while (node.next()) {
            if (!isPageRankSimilarToVektor(node)) {
                return false;
            }
        return true;
    }
    /*
    compare vektor and pagerank of given node by given COMPARE_DELTA
```

```
private boolean isPageRankSimilarToVektor(ResultSet node) throws SQLException

double vektor = node.getDouble("Vektor");
    double pageRank = node.getDouble("pagerank");
    return !(Math.abs(vektor - pageRank) >= COMPARE_DELTA);

private double getEqualDistributionVektorValue() throws SQLException {
    if (equalDistributionValue == null) {
        equalDistributionValue = (1.0 / dbAccess.getNodesCount());
    }
    return equalDistributionValue;
}
```

: DataAccess

```
package Ranker.PageRank;
import java.sql.*;
public class DataAccess {
    private static DataAccess access;
    private PreparedStatement initVektorStatement;
    private PreparedStatement[] resetPageRankTableStatements;
    private PreparedStatement getUrlsStatement;
    private PreparedStatement setOutgoingStatement;
    private PreparedStatement countNodesStatement;
    private PreparedStatement getPageRankTableStatement;
    private PreparedStatement prepareDampStatement;
    private PreparedStatement countOutgoingLinksStatement;
    private PreparedStatement getOutgoingLinksStatement;
    private PreparedStatement increasePageRankStatement;
    private PreparedStatement prepareCalculationStatement;
    private PreparedStatement insertUrlStatement;
    private PreparedStatement getAllUrlsStatement;
    private DataAccess() throws SQLException {
        init();
    }
    public static Connection getConnection() {
        Connection connection = null;
        try {
            Class.forName("com.mysql.jdbc.Driver");
            connection = DriverManager.getConnection(
                    "jdbc:mysql://localhost:3306/search_engine", "root", "");
        } catch (Exception e) {
            e.printStackTrace();
        }
        return connection;
    public static DataAccess getAccess() throws SQLException {
        if (access == null) {
            access = new DataAccess();
        return access;
    }
    private void init() throws SQLException {
        Connection dbConnection = getConnection();
        initVektorStatement = dbConnection.prepareStatement("Update pagerank SET
vektor=? WHERE doc_url_id>=? AND doc_url_id<=?;");</pre>
        resetPageRankTableStatements = new PreparedStatement[]{
                dbConnection.prepareStatement("DELETE FROM pagerank;"),
                dbConnection.prepareStatement("ALTER TABLE pagerank
AUTO_INCREMENT=1;")
        };
        getUrlsStatement = dbConnection.prepareStatement("SELECT * FROM urls WHERE
id>=? AND id<=?;");
        getAllUrlsStatement = dbConnection.prepareStatement("SELECT * FROM
```

```
urls;");
        setOutgoingStatement = dbConnection.prepareStatement("UPDATE pagerank SET
outgoing = ? WHERE doc_url_id=? AND (doc_url_id>=? AND doc_url_id<=?);");</pre>
        countNodesStatement = dbConnection.prepareStatement("SELECT Count(*) AS c
FROM urls;");
        getPageRankTableStatement = dbConnection.prepareStatement("SELECT * FROM
pagerank WHERE doc_url_id>=? AND doc_url_id<=?;");</pre>
        prepareDampStatement = dbConnection.prepareStatement("UPDATE pagerank SET
pagerank=pagerank*?+?*? WHERE doc url id>=? AND doc url id<=?;");</pre>
        countOutgoingLinksStatement = dbConnection.prepareStatement("SELECT
Count(*) AS c FROM links WHERE source = ?;");
        getOutgoingLinksStatement = dbConnection.prepareStatement("SELECT * FROM
links WHERE source=?;");
        increasePageRankStatement = dbConnection.prepareStatement("Update pagerank
SET pagerank=pagerank+? WHERE id=? AND (doc_url_id>=? AND doc_url_id<=?);");</pre>
        prepareCalculationStatement = dbConnection.prepareStatement("Update
pagerank SET vektor=pagerank, pagerank=0 WHERE doc_url_id>=? AND doc_url_id<=?;");</pre>
        insertUrlStatement = dbConnection.prepareStatement("INSERT INTO pagerank
(doc_url_id) VALUES (?)");
    public void resetPageRankTable() throws SQLException {
        executeMultiStatement(resetPageRankTableStatements);
    private void executeMultiStatement(PreparedStatement[] preparedStatements)
throws SQLException {
        for (PreparedStatement preparedStatements) {
            preparedStatement.execute();
        }
    }
    public boolean initVektor(Double equalDistributionVektorValue, long startId,
long endId) throws SQLException {
        initVektorStatement.setDouble(1, equalDistributionVektorValue);
        initVektorStatement.setDouble(2, startId);
        initVektorStatement.setDouble(3, endId);
        return initVektorStatement.execute();
    }
    public ResultSet getUrls(long startId, long endId) throws SQLException {
        getUrlsStatement.setLong(1, startId);
        getUrlsStatement.setLong(2, endId);
        return getUrlsStatement.executeQuery();
    }
    public ResultSet getAllUrls() throws SQLException {
        return getUrlsStatement.executeQuery();
    public ResultSet getPageRankTable(long startId, long endId) throws
SQLException {
        getPageRankTableStatement.setLong(1, startId);
        getPageRankTableStatement.setLong(2, endId);
        return getPageRankTableStatement.executeQuery();
    }
    public boolean setOutgoingLinksValue(int outgoing, long id,long startId,long
endId) throws SQLException {
```

```
setOutgoingStatement.setInt(1, outgoing);
        setOutgoingStatement.setLong(2, id);
        setOutgoingStatement.setLong(3, startId);
        setOutgoingStatement.setLong(4, endId);
        return setOutgoingStatement.execute();
    }
    public long getNodesCount() throws SQLException {
        ResultSet resultSet = countNodesStatement.executeQuery();
        resultSet.first();
        return resultSet.getLong("c");
    }
    public boolean dampPageRank(double dampingFactor, double
equalDistributionVektorValue, long startId, long endId) throws SQLException {
        prepareDampStatement.setDouble(1, dampingFactor);
        prepareDampStatement.setDouble(2, equalDistributionVektorValue);
        prepareDampStatement.setDouble(3, 1 - dampingFactor);
        prepareDampStatement.setDouble(4, startId);
        prepareDampStatement.setDouble(5, endId);
        return prepareDampStatement.execute();
    }
    public int countOutgoingLinks(long sourceID) throws SQLException {
        countOutgoingLinksStatement.setLong(1, sourceID);
        ResultSet resultSet = countOutgoingLinksStatement.executeQuery();
        resultSet.first();
        return resultSet.getInt("c");
    }
    public ResultSet getOutgoingLinks(long sourceID) throws SQLException {
        getOutgoingLinksStatement.setLong(1, sourceID);
        return getOutgoingLinksStatement.executeQuery();
    }
    public boolean increasePageRank(double increasingValue, long targetID, long
startId, long endId) throws SQLException {
        increasePageRankStatement.setDouble(1, increasingValue);
        increasePageRankStatement.setLong(2, targetID);
        increasePageRankStatement.setLong(3,startId);
        increasePageRankStatement.setLong(4,endId);
        return increasePageRankStatement.execute();
    }
    public boolean prepareCalculation(long startId, long endId) throws
SQLException {
        prepareCalculationStatement.setLong(1,startId);
        prepareCalculationStatement.setLong(2,endId);
        return prepareCalculationStatement.execute();
    }
    public boolean insertUrl(long docUrlId) throws SQLException {
        insertUrlStatement.setLong(1, docUrlId);
        return insertUrlStatement.execute();
    }
}
```

بخش جستجو

این بخش با بهره گیری از اطلاعات رتبه های tf_idf و pagerank در دیتابیس لینک هایی که شامل کلمه ورودی در نرم افزار جستجو باشند را می یابد و به ترتیب رتبه ای که دارند نمایش می دهد.

این بخش با به کارگیری فریمورک laravel که یکی از فریمورک های طراحی وب سایت به زبان php است انجام شده است. جهت استفاده از این بخش ابتدا نرم افزارهای composer و لاراول باید نصب شوند.

برای اجرا از کد ذیل استفاده می شود.

php artisan serve

در بین فایل هایی که در پروژه وب سایت جستجو است دو فایل SearchController.php و index.blade.php کدهای اصلی بخش search را پردازش میکنند.

SearchController.php : در این کلاس پس از دریافت کلمه مورد جستجو در متد index آن را ابتدا به حروف کوچک تبدیل کرده و سپس tokenize می کند. بعد از این مرحله در صورتی که کلمه مورد جستجو در دیتابیس وجود داشته باشد لینک های مربوط به آن را به ترتیب امتیاز رتبه به فایل index.balde.php بر میگرداند.

Index.blade.php: این فایل ظاهر موتور جستجوگر را نشان میدهد. با بهره گیری از فرم ها در html ورودی فیلد جستجو را به کلاس SearchController پاس می دهد و پس از پردازش توسط این کلاس لیست لینک های نتیجه را از این کلاس دریافت میکند و به عنوان results به کاربر نمایش می دهد.

فایل SearchController.php:

<?php

```
namespace App\Http\Controllers;
use App\Classes\Stemmer;
use App\Models\Pagerank;
use App\Models\TfIdf;
use App\Models\Word;
use App\Models\WordDoc;
use Illuminate\Http\Request;
class SearchController extends Controller
{
    public function index(Request $request)
        $s = "";
        $show_results = false;
        $results = [];
        $search_method = 1;//1:tf_idf 2:page rank
        $word_id = 0;
        if ($request->search) {
            $s = $request->search;
            $s2 = Stemmer::stem($s);
            try {
                $word_id = $this->findWordId($s2)->id;
                //page rank method
                $urls = $this->findWordIdUrls($word_id);
                $page_rank_array = $this->findPageRankUrls($urls);
                //tf idf
                $tf_idf_array = $this->findTfIdfUrls($word_id);
                if ($search_method == 1) {
                    $results = $tf_idf_array;
                    $results = $page_rank_array;
                $show_results = true;
            } catch (\Exception $e) {
                $show_results = true;
            }
        }
        return view('index', compact('s', 'show_results', 'search_method', 're
sults'));
    }
    public function findWordId($word)
    {
```

```
return Word::where("word", "=", $word)->first();
    }
    public function findTfIdfUrls($word_id)
        return TfIdf::select("doc_url_id", "score")-
>where("word_id", "=", $word_id)->orderBy("score", "DESC")->distinct()->get();
    }
    public function findWordIdUrls($word_id)
        return WordDoc::where("word_id", "=", $word_id)->get();
    }
    public function findPageRankUrls($urls)
        a = [];
        if (!empty($urls)) {
            $a = Pagerank::where("doc_url_id", "=", $urls[0]->doc_url_id);
            $size = sizeof($urls);
            for ($i = 1; $i < $size; $i++) {</pre>
                $a = $a->orWhere("doc_url_id", "=", $urls[$i]->doc_url_id);
            return $a->orderBy("pagerank", "DESC")->distinct()->get();
        }
        return $a;
    }
}
```

: index.blade.php فایل

```
<!DOCTYPE html>
<html lang="en">
<head>
    <meta charset="UTF-8">
    <meta name="viewport" content="width=device-width, initial-scale=1.0">
    <meta http-equiv="X-UA-Compatible" content="ie=edge">
    <title>WebSearchEngine</title>
    <link rel="stylesheet" href="https://stackpath.bootstrapcdn.com/bootstrap/</pre>
4.3.1/css/bootstrap.min.css"
         integrity="sha384-
ggOyR0iXCbMQv3Xipma34MD+dH/1fQ784/j6cY/iJTQU0hcWr7x9JvoRxT2MZw1T" crossorigin=
"anonymous">
   <!-- Material Design Bootstrap -->
    <link href="https://cdnjs.cloudflare.com/ajax/libs/mdbootstrap/4.8.9/css/m</pre>
db.min.css" rel="stylesheet">
</head>
<body style="background-color: #f7f7f7">
<form action="{{route('index')}}" method="get">
   @csrf
   <h1 style="text-align: center;margin-top:100px;font-size:70px"><span</pre>
           class="badge badge-dark">WEB SEARCH ENGINE</span>
   </h1>
    <div class="card" style="margin-right: 20%;margin-left: 20%;margin-</pre>
top: 40px;">
       <div class="card-body">
           <div class="form-group">
               <input type="text" class="form-</pre>
control" name="search" id="search"
                      placeholder="Enter your search query..." value="{{$$}}"
                      required>
           </div>
           <div style="text-align: center">
               <button class="btn btn-primary btn-</pre>
lg active" type="submit">Search</button>
           </div>
       </div>
    </div>
</form>
@if($show_results)
   <nav aria-label="breadcrumb">
       left:10%;margin-top:30px">
           current="page">{{sizeof($results)}} Results
```

```
</nav>
    <div style="margin-bottom: 100px">
        @php $i=1; @endphp
        @foreach($results as $result)
            @php
                $url=\App\Models\Url::find($result->doc url id);
                $url_link=$url->url;
                $url_title=$url->title;
            @endphp
            <a href="{{$url_link}}">
                <div class="card" style="margin-right: 10%;margin-</pre>
left: 10%;margin-top: 30px;padding: 20px">
                    {{$i}}
                    <hr>>
                    {{$url link}}
                    <hr>
                     {{$url_title}}
                </div>
            </a>
            @php $i=$i+1; @endphp
        @endforeach
    </div>
@endif
<script src="https://code.jquery.com/jquery-3.3.1.slim.min.js"</pre>
        integrity="sha384-
q8i/X+965Dz00rT7abK41JStQIAqVgRVzpbzo5smXKp4YfRvH+8abtTE1Pi6jizo"
        crossorigin="anonymous"></script>
<script src="https://cdnjs.cloudflare.com/ajax/libs/popper.js/1.14.7/umd/poppe</pre>
r.min.js"
        integrity="sha384-
UO2eTOCpHqdSJQ6hJty5KVphtPhzWj9WO1clHTMGa3JDZwrnQq4sF86dIHNDz0W1"
        crossorigin="anonymous"></script>
<script src="https://stackpath.bootstrapcdn.com/bootstrap/4.3.1/js/bootstrap.m</pre>
in.js"
        integrity="sha384-
JjSmVgyd0p3pXB1rRibZUAYoIIy60rQ6VrjIEaFf/nJGzIxFDsf4x0xIM+B07jRM"
        crossorigin="anonymous"></script>
<script type="text/javascript"</pre>
        src="https://cdnjs.cloudflare.com/ajax/libs/mdbootstrap/4.8.9/js/mdb.m
in.js"></script>
</body>
</html>
```

بخش یایگاه داده

جدول های دیتابیس مطابق با نمودار زیر میباشد.

جدول websites وب سایت هایی که عملیات crawling در موردشان انجام می شود را لیست کرده است. در جدول websites لینک های یافت شده در هر اrr را لیست کرده لینک های یافت شده در وب سایت ها لیست می شود. جدول words کلمات کلیدی یافت شده در هر اrr را لیست کرده است. در جدول word_doc کلمات کلیدی با ذکر اrr و تعداد تکرار آن آورده شده است. در جدول word_doc کلمات کلیدی با ذکر pagerank و tfidf امتیاز هر یک از url ها ثبت شده است.

